

Sistema de Clasificación Automática de Actividades Motoras Mediante Visión por Computador y
Aprendizaje Automático para el Análisis de Patrones de Movimiento Humano

Algoritmos y Programación III

2025-II

Gabriel Escobar - Sebastián Erazo - Rony Ordoñez

Profesor

Milton Sarria Paja

Noviembre de 2025

Cali, Colombia

i. Abstract

El análisis objetivo del movimiento humano es fundamental en la evaluación clínica de la progresión de enfermedades neurodegenerativas, tales como el Parkinson, donde los patrones motores pueden deteriorarse lentamente y de manera sutil. Este proyecto presenta un sistema automático de reconocimiento de actividades motoras en tiempo real usando únicamente una cámara convencional, visión por computador y aprendizaje automático. El proceso comienza con la captura de video y la anotación manual de actividades motoras específicas. A partir de estas grabaciones, se emplea *MediaPipe Pose* para la extracción de coordenadas articulares 2D, seguido del cálculo de características cinemáticas derivadas, tales como el ángulo de rodilla, inclinación del tronco y distancias corporales relativas. Con estas características se entrena un modelo supervisado basado en *Random Forest*, optimizado mediante *Grid Search*, logrando una precisión final del 81.5% y un rendimiento especialmente sólido en actividades dinámicas como caminar y girar. Los resultados demuestran la viabilidad de un sistema no invasivo, accesible y de bajo costo para el monitoreo del movimiento humano, con potencial aplicación en contextos clínicos, de rehabilitación y seguimiento remoto.

i. Introducción

Contexto del Problema

Las enfermedades neurodegenerativas, como el Parkinson, la esclerosis lateral amiotrófica (ELA) y la ataxia cerebelosa, afectan de manera directa la coordinación y el control motor, provocando alteraciones progresivas en la postura, el equilibrio y la capacidad de desplazamiento. La evolución de estos cuadros suele ser lenta y sutil, por lo que su seguimiento clínico requiere evaluaciones frecuentes y precisas que permitan determinar la efectividad de tratamientos, intervenciones terapéuticas y procesos de rehabilitación. Tradicionalmente, esta evaluación del movimiento se realiza mediante observación clínica directa por parte de especialistas, lo que introduce un grado significativo de subjetividad. Otra alternativa son los sistemas avanzados de captura de movimiento basados en sensores corporales o laboratorios de análisis biomecánico, los cuales pueden ofrecer mediciones más objetivas, pero suelen ser costosos, invasivos, dependientes de equipamiento especializado y difíciles de implementar en instituciones con recursos limitados. Como resultado, el seguimiento rutinario del movimiento humano continúa siendo un desafío en entornos reales y cotidianos.

Motivación del Proyecto

El desarrollo reciente de técnicas de visión por computador ha permitido analizar el movimiento humano de manera no invasiva, utilizando únicamente cámaras convencionales y modelos computacionales capaces de extraer información corporal relevante. Herramientas como *MediaPipe Pose* permiten detectar articulaciones en tiempo real con alta precisión y bajo costo computacional, lo que posibilita la creación de sistemas accesibles, portátiles y escalables. En este sentido, surge la necesidad de construir soluciones que automaticen la identificación de patrones motores, reduzcan la dependencia de evaluaciones subjetivas y faciliten la disponibilidad de herramientas clínicas replicables y no invasivas. El proyecto se plantea precisamente como una respuesta técnica a esta necesidad.

Objetivos del Proyecto

Objetivo General:

El objetivo general de este proyecto es diseñar y desarrollar un sistema de reconocimiento automático de actividades motoras humanas en tiempo real, utilizando técnicas de visión por computador y modelos de aprendizaje supervisado. El sistema busca identificar y clasificar diferentes acciones corporales a partir del análisis de coordenadas articulares obtenidas mediante estimación de pose, con el fin de contribuir a la evaluación objetiva de patrones de movimiento humano. Este enfoque pretende ofrecer una alternativa no invasiva, accesible y replicable, que pueda ser utilizada eventualmente en contextos clínicos, de rehabilitación o monitoreo remoto de progresión motora.

Objetivo Específicos:

- **Construcción del dataset:** Crear un conjunto de datos anotado a partir de videos donde se registran diversas actividades motoras, asegurando precisión en la delimitación temporal de cada acción.
- **Extracción de características cinemáticas:** Obtener coordenadas articulares mediante MediaPipe Pose y derivar de ellas métricas biomecánicas relevantes, como ángulos, inclinaciones y distancias corporales.
- **Entrenamiento y optimización del modelo:** Implementar un modelo supervisado de clasificación (Random Forest) y ajustar sus hiper parámetros para mejorar su capacidad de generalización.
- **Evaluación del rendimiento:** Medir la precisión del sistema mediante métricas como F1-Score y analizar la matriz de confusión para determinar qué actividades son reconocidas con mayor o menor efectividad.

Contribuciones del Trabajo

- Un sistema funcional de clasificación en tiempo real.
- Un conjunto de datos anotados manualmente.
- Identificación de características biomecánicas clave para la diferenciación de actividades.

iii. Teoría

Fundamentos de Visión por Computador

La estimación de pose humana es el proceso de identificar posiciones articulares del cuerpo en imágenes o video. *MediaPipe Pose* emplea redes neuronales ligeras para detectar puntos clave como hombros, cadera, rodillas y tobillos con alta estabilidad.

Características Cinemáticas

Se derivan características biomecánicamente significativas:

- **Ángulo de rodilla:** distingue sentarse/levantarse.
- **Inclinación del tronco:** asociada al equilibrio postural.
- **Distancia hombro–cadera:** indica postura erguida o flexionada.
- **Estadísticas temporales:** media y desviación captan estabilidad y oscilación.

Clasificación Supervisada

Se emplea *Random Forest* por su:

- Robustez ante ruido,
- Capacidad de manejar relaciones no lineales,
- Interpretabilidad de características.

La evaluación se realiza mediante:

- *Precision, Recall, F1-Score*, y
- Matriz de confusión multiclase.

Trabajos Relacionados

Sistemas similares existen en análisis deportivo y vigilancia, pero pocos se orientan específicamente al seguimiento clínico accesible y no invasivo.

iv. Metodología

Marco Metodológico: CRISP-DM

Se siguieron etapas de:

1. Comprensión del problema,
2. Análisis y preparación de datos,
3. Modelado,
4. Evaluación,
5. Despliegue.

Recolección de Datos

Se grabó a los sujetos ejecutando una secuencia de siete actividades motoras. El dataset fue posteriormente duplicado mediante recolección colaborativa.

Anotación y Etiquetado

Se utilizó Label Studio para marcar inicio y fin de cada actividad.
Formato final: JSON.

Extracción de Características


Se procesaron los videos con MediaPipe Pose. Luego se calcularon ángulos, distancias y estadísticas.

Preparación del Dataset

Tamaño final: **1453 muestras y 6 características numéricas**, estratificadas en proporción 80/20 para train/test.

Entrenamiento del Modelo


Se entrenó un *Random Forest* base y luego se optimizó mediante Grid Search.



v. Resultados

Desempeño del Modelo Base


- Accuracy entrenamiento: **1.00**
- Accuracy prueba: **0.796**
- Indicios de sobreajuste.



Modelo Optimizado

Accuracy final: 81.5%

Mejoras en clases dinámicas como caminar adelante y atrás.



vi.

Results Analysis

- Fortalezas: distingue actividades dinámicas con alta efectividad.
- Limitaciones: confusión entre posturas estáticas debido a variabilidad mínima.
- El ajuste de hiper parámetros redujo sobreajuste sin penalizar generalización.

vii. Conclusions and Future Work

Se logró un sistema funcional y no invasivo con desempeño competitivo. Sin embargo, se requiere:

- Mayor diversidad en sujetos y entornos,
- Inclusión de secuencias temporales (LSTM),
- Validación clínica con pacientes reales.

viii. References

- [1] F. Zhang, H. Bazavan, A. Papandreou, D. Meier, M. Riegler, and R. Soricut, “MediaPipe Hands: On-device Real-time Hand Tracking,” *Google Research*, 2020. Disponible en: <https://mediapipe.dev>
- [2] G. Hee Lee and A. Ali, “MediaPipe Pose: Real-Time Body Pose Tracking for Fitness Applications,” *Google AI Blog*, 2021.
- [3] L. Breiman, “Random Forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [4] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [5] J. Shotton et al., “Real-Time Human Pose Recognition in Parts from a Single Depth Image,” *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2011.
- [6] H. K. Samy, M. T. Ahmed, and A. E. Taha, “Human Activity Recognition Using Random Forest Machine Learning Algorithm,” *International Journal of Advanced Computer Science and Applications*, vol. 11, no. 12, pp. 85–92, 2020.
- [7] C. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [8] W. Hsu and M. Wu, “Biomechanical Assessment of Sit-to-Stand Movement in Parkinson’s Disease,” *Journal of Motor Behavior*, vol. 52, no. 4, pp. 478–492, 2020.
- [9] M. Martínez-García, A. Muñoz-Organero, and J. L. Rojo, “Real-time gait analysis for Parkinson’s disease monitoring using wearable inertial sensors,” *IEEE Sensors Journal*, vol. 19, no. 24, pp. 12002–12010, 2019.
- [10] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, “CRISP-DM 1.0 Step-by-Step Data Mining Guide,” *The CRISP-DM Consortium*, 2000.
- [11] Heartex Labs, “Label Studio: Open Source Data Labeling Tool,” 2022. Disponible en: <https://labelstud.io>